

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



DETEKCIA OBLIČKOVÝCH KAMEŇOV V CT SNÍMKACH

Diplomová práca

2022

Bc. Jana Oravcová

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY



DETEKCIA OBLIČKOVÝCH KAMEŇOV V CT SNÍMKACH

Diplomová práca

Študijný program: Aplikovaná informatika
Študijný odbor: 2511 Aplikovaná informatika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: RNDr. Zuzana Černeková, PhD.

Bratislava, 2022

Bc. Jana Oravcová



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Bc. Jana Oravcová
Študijný program: aplikovaná informatika (Jednoodborové štúdium, magisterský II. st., denná forma)
Študijný odbor: informatika
Typ záverečnej práce: diplomová
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Detekcia obličkových kameňov v CT snímkach
Kidney stone detection in CT images

Anotácia: Detegovať močové kamene v snímkach z CT zariadenia s využitím neurónových sietí. Naštudovať problematiku spracovania medicínskych dát pomocou neurónových sietí. Analyzovať existujúce riešenia publikované v dostupnej odbornej literatúre. Navrhnuť sieť vhodnú na detekciu močových kameňov v CT snímkach. Túto sieť otestovať a vyhodnotiť výsledky.

Cieľ: Detegovať močové kamene v snímkach z CT zariadenia s využitím neurónových sietí. Naštudovať problematiku spracovania medicínskych dát pomocou neurónových sietí. Analyzovať existujúce riešenia publikované v dostupnej odbornej literatúre. Navrhnuť sieť vhodnú na detekciu močových kameňov v CT snímkach. Túto sieť otestovať a vyhodnotiť výsledky.

Vedúci: RNDr. Zuzana Černeková, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: prof. Ing. Igor Farkaš, Dr.
Dátum zadania: 30.09.2020

Dátum schválenia: 08.10.2020

prof. RNDr. Roman Ďurikovič, PhD.
garant študijného programu

.....
študent

.....
vedúci práce

Čestne prehlasujem, že túto diplomovú prácu som vypracovala samostatne len s použitím uvedenej literatúry a za pomoci konzultácií u môjho školiteľa.

Bratislava, 2022

.....

Bc. Jana Oravcová

Pod'akovanie

Abstrakt

Klíčové slová:

Abstract

Keywords:

Obsah

| | | |
|----------|--|-----------|
| 1 | Úvod do problematiky | 1 |
| 2 | Teoretické východiská | 2 |
| 2.1 | Medicínske dáta | 2 |
| 2.1.1 | Augmentácia dát | 3 |
| 2.2 | Súradnicový systém pacienta | 4 |
| 2.3 | Počítačová tomografia | 4 |
| 2.4 | DICOM | 7 |
| 2.5 | Umelé neurónové siete | 8 |
| 2.6 | Konvolučné neurónové siete | 11 |
| 2.7 | Trénovanie neurónovej siete | 12 |
| 3 | Predchádzajúce riešenia | 14 |
| 3.1 | Detekcia močových kameňov | 14 |
| 3.2 | Detekcia pľúcnych nodulov | 16 |
| 3.3 | Detekcia plakov v srdcovej tepne | 19 |
| 4 | Návrh modelu | 20 |
| 5 | Implementácia | 21 |
| 6 | Výsledky | 22 |

OBSAH

ix

7 Závěr

23

Kapitola 1

Úvod do problematiky

Kapitola 2

Teoretické východiská

Pre lepšie pochopenie praktickej časti práce a samotnej implementácie riešenia problému je potrebné si vysvetliť niekoľko dôležitých konceptov. V tejto časti sa zameriame na pôvod a reprezentáciu medicínskych dát a opíšeme si teóriu konvolučných neurónových sietí.

2.1 Medicínske dáta

V predošlých častiach sme písali o tom, že je veľký dopyt po riešeniach pre automatickú detekciu a iné riešenia zahrňujúce metódy hlbokého učenia. Na to, aby vedci či verejnosť bola schopná v tejto oblasti robiť nejaký výskum je dôležité mať dostatok dát. Medicínske dáta sú avšak veľmi citlivým obsahom, ktorý nie je tak jednoduché získať verejne. Najčastejšie je prekážkou vo zverejnení týchto dát HIPAA v USA alebo GDPR v Európe. Zatiaľ čo v niektorých kategóriách medicínskych dát je veľa verejných datasetov, stále je veľa oblastí medicíny, kde sú dáta verejne dostupné ako tomu bolo aj v prípade tejto diplomovej práce. Dáta je teda v takomto prípade možné získať len zo súkromných zdrojov vrámci spoluprác s nemocnicami či inými vý-

skumnými inštitúciami ako napríklad univerzitami, ktoré tieto dáta získali zrejme obdobným spôsobom. V oboch prípadoch sú dáta najprv anonymizované, čo znamená, že informácie, ktoré by akokoľvek identifikovali osobu, o ktorej dáta sa jedná, sú odstránené. Tento proces avšak nemusí byť sto-percentný a aj anonymizovaným dátam sa dá zistiť majiteľ v prípade, že sú dáta prepojené s nejakým iným datasetom, ktorý by akokoľvek poukazoval na príslušnosť anonymizovaných dát [?].

2.1.1 Augmentácia dát

Aj napriek nedostatočnému množstvu dát sú spôsoby ako výskumníci môžu pokračovať vo svojich prácach a jedn. Augmentácia dát je proces, pri ktorom si umelo vytvoríme nové dáta nejakou úpravou pôvodných dát. V kontexte obrazových dát, ktorými sa v tejto práci zaoberáme to sú najmä operácie ako rotácia obrazu o nejaký uhol, horizontálny alebo vertikálne otočenie, vyhladenie obrazu nejakým filtrom či náhodná zmena jasu jednotlivých pixelov a iné. Všetky tieto transformácie by avšak mali byť aplikované tak, aby zmenili dáta správnym spôsobom a stále zachovali ich charakter. V prípade medicínskych dát je najpoužívanejšou transformáciou pri augmentácií dát rotácia obrazu a otočenie obrazu v horizontálnom alebo vertikálnom smere.


Väčšina frameworkov na hlboké učenie či spracovanie obrazu už ponúka vstavané metódy na aplikovanie týchto transformácií na vstupný obraz, čím značne uľahčujú ich aplikáciu v rámci neurónovej siete či ešte vo fáze spracovania obrazu.

2.2 Súradnicový systém pacienta

Aby sme lepšie chápali nasledujúce časti, je vhodné opísať si súradnicový systém pacienta. V kontexte zobrazovacích prístrojov a rádiologických vyšetrení sa jedná o systém, ktorý popisuje polohu každého bodu tela pacienta. Tento systém pozostáva z 3 rovín:

1. Axiálna rovina - pri pohľade na pacienta spredu je to horizontálna rovina rovnobežná s podlahou
2. Sagitálna rovina - pri pohľade na pacienta spredu je to vertikálna rovina, ktorá rozdeľuje pacienta na pravú a ľavú časť
3. Koronálna rovina - pri pohľade na pacienta spredu je to vertikálna rovina, ktorá rozdeľuje pacienta na prednú a zadnú časť

Jednoduchý vizuálny opis týchto rovín je možné vidieť na obrázku 2.1.




Obr. 2.1: Vizualizácia troch osí CT skenu

2.3 Počítačová tomografia

Počítačová tomografia (anglicky computed tomography - CT) je rádiologická vyšetровacia metóda, ktorá funguje na princípe röntgenového žiarenia. Zaria-

denie zodpovedné za toto vyšetrenie sa nazýva tiež CT skener. Na jeho vývoji sa podieľalo v 20. storočí niekoľko vedcov a držiteľom patentu bol v rokoch 1975-1992 profesor biológie a biofyziky Robert S. Ledley. Na rozdiel od klasického röntgenového vyšetrenia, ktoré spraví snímku len v jednom smere zameranú na skúmanú oblasť, CT skener je rotujúce zariadenie, ktoré vyžaruje röntgenového lúče a zároveň deteguje mieru absorpcie žiarenia tkanivom pod viacerými uhlami. Po každej rotácii zariadenia okolo pacienta počítač prístroja zrekonštruuje 2D obraz v axiálnej osi korešpondujúcou s oblasťou kde bolo zariadenie namierené - rez CT skenu. Následne prístroj pacienta posunie pozdĺž prístroja o vzdialenosť, ktorá neskôr udáva hrúbku rezu a začne so zostrojovaním ďalšieho rezu. Schematickú reprezentáciu tohto procesu je možné vidieť na obrázku 2.2




Obr. 2.2: Schematická reprezentácia fungovania CT skeneru (zdroj: [Sue17])

Okrem rezov v axiálnej osi CT je počítač schopný zrekonštruovať obraz ešte v sagitálnej a koronálnej osi. Informácia, ktorú každý rez skenu zachytáva reprezentuje schopnosť daného tkaniva absorbovať röntgenové žiarenie. Túto mieru udáva Hounsfieldova jednotka - HU. Hodnoty sú vycentrované okolo miery absorpcie vody 0HU s najnižšou hodnotou -1000HU pre absorpciu vzduchu. Hodnoty vyššie ako 0HU reprezentujú orgány, kosti a iné materiály ako napríklad kovy, ktoré sú často obsiahnuté v rôznych konštrukciách použitých pri operáciách.

Počítač CT skenu je schopný uchovať pre každý pixel hodnoty reprezentované 12 bitami, čo znamená, že vie teoreticky uložiť hodnoty v intervale od -1024 do 3071. Aby sme boli schopní zobrazíť tieto hodnoty na obrazovke počítača, mapujeme ich na úrovne šedej farby a výsledku sa teda obraz javí ako šedotónový. Na mapovanie hodnôt sa používa tzv. okno a jeho dva parametre - šírka okna a jeho stred.

V praxi má rádiológ možnosť v rôznych softvéroch na zobrazovania a anotáciu medicínskych dát upraviť mapovanie pomocou tzv. okna mapovania, určeného dvomi parametrami - šírka okna a jeho stred. Šírka okna udáva kontrast jednotlivých pixelov obrazu a jeho stred určuje ich jas. Na obrázku 2.3 vidíme v strede pôvodný obraz, smerom hore zvýšime stred okna čím znížime jas a naopak smerom dole sa zníži stred okna a jas sa zvýši. Smerom doprava sa zmenšuje šírka okna, čo zapríčiní zvýšenie kontrastu a naopak smerom vľavo sa šírka zväčší čím sa zníži kontrast.



Obr. 2.3: Zmena obrazu pri úprave šírky a stredu okna mapovania

Každý bod zostrojených rezov v skutočnosti odpovedá nejakému objemu. V 2D priestore sa každý bod obrazu nazýva pixel a v prípade 3D dát sa bod nazýva voxelom. Voxel má svoje rozmery, ktoré v prípade rezov skenu určuje buď rádiológ na počítači skeneru alebo sú vypočítané podľa rozme-

rov vyšetrovanej oblasti. Hĺbka voxelu je daná hrúbkou rezu, ktorá závisí od konkrétneho prístroja a taktiež od vyšetrovanej oblasti. Výška a šírka sú naopak vypočítané ako podiel šírky/výšky oblasti, ktorá má byť na obraze zobrazená v milimetroch a počtu stĺpcov/riadkov matice reprezentujúcej obraz. Zvyčajne je rozmer matice 512 riadkov a 512 stĺpcov. Skutočné rozmery voxelu sú veľmi dôležitým údajom napríklad v prípade určovania veľkosti nálezov.

2.4 DICOM

Obrazové medicínske dáta sa najčastejšie uchovávajú vo formáte DICOM, ktorý reprezentuje štandard akým sú distribuované, ukladané a tlačené medicínske dáta vytvorené zobrazovacími technikami ako CT a inými.


DICOM súbor pozostáva z dvoch hlavných častí - hlavičky a samotných obrazových dát. Hlavička obsahuje metadáta, ktoré sú štruktúrované podľa tzv. tagov - istých kľúčových slov a kódov určujúcich názov informácie. Tagy sú organizované do skupín podľa ich významu ako napríklad informácie o pacientovi alebo parametre vyšetrovacieho prístroja. Na obrázku 2.4 môžeme vidieť niekoľko tagov zobrazených vrámci DICOM súboru v softvéri Micro Dicom Viewer.

| (Group,Element) | TAG Description | VR | V.. | Length | Value |
|-----------------|------------------------------------|----|-----|--------|---|
| (0002,0000) | File Meta Information Group Length | UL | 1 | 4 | 192 |
| (0002,0001) | File Meta Information Version | OB | 1 | 2 | 00/01 |
| (0002,0002) | Media Storage SOP Class UID | UI | 1 | 26 | 1.2.840.10008.5.1.4.1.1.2 |
| (0002,0003) | Media Storage SOP Instance UID | UI | 1 | 56 | 1.3.12.2.1107.5.1.4.77943.30000020100805510889500008855 |
| (0002,0010) | Transfer Syntax UID | UI | 1 | 20 | 1.2.840.10008.1.2.1 (Explicit VR Little Endian) |
| (0002,0012) | Implementation Class UID | UI | 1 | 28 | 1.3.6.1.4.1.20468.0.1.1.6.3 |
| (0002,0013) | Implementation Version Name | SH | 1 | 8 | TMDTK163 |
| (0008,0005) | Specific Character Set | CS | 1 | 10 | ISO_IR 101 |
| (0008,0008) | Image Type | CS | 4 | 38 | ORIGINAL/PRIMARY/LOCALIZER/CT_SOM5 TOP |
| (0008,0016) | SOP Class UID | UI | 1 | 26 | 1.2.840.10008.5.1.4.1.1.2 |
| (0008,0018) | SOP Instance UID | UI | 1 | 56 | 1.3.12.2.1107.5.1.4.77943.30000020100805510889500008855 |

Obr. 2.4: Tagy DICOM súboru zobrazené v softvéri Micro Dicom Viewer

Medzi veľmi dôležité tagy patria aj identifikátory, ktoré jedinečne určujú rôzne atribúty a medziiným napríklad štúdiu, ktorá predstavuje súhrn

všetkých dokumentov vytvorených pre účel vyšetrenia pacienta pri návšteve nemocnice. Tento identifikátor je jedinečný globálne, čo znamená, že každé vyšetrenie kdekoľvek na svete je ním jednoznačne určené. Ďalším dôležitým identifikátorom je identifikátor série, ktorá predstavuje jedno nastavenie vrámci vyšetrenia, a teda v prípade CT vyšetrenia to môže byť napríklad poloha pacienta. Vrámcu jednej série následne súbor obsahuje inštancie, ktoré predstavujú najčastejšie samotné obrazové dáta. Každá inštancia vrámci série je vlastne DICOM súborom s hlavičkou, ktorá obsahuje všetky tagy spoločné pre pacienta, štúdiu a sériu, a tak je aj samostatne distribuovateľná. Na obrázku 2.5 vidíme príklad takejto štruktúry zobrazenej v softvéri Micro Dicom Viewer




Obr. 2.5: Ukážka možnej štruktúry DICOM súborov v softvéri Micro Dicom Viewer

2.5 Umelé neurónové siete

Umelé neurónové siete (ANN) predstavujú výpočtový systém, ktorý je do veľkej miery inšpirovaný skutočným nervovým systémom človeka. Rovnako ako náš nervový systém je zložený z neurónov, ktoré si medzi sebou predávajú pomocou signálov informácie, aj umelé neurónové siete majú ako základnú stavebnú jednotku takýto neurón. Fungovanie tohto systému si opíšeme na jednoduchšej architektúre umelej neurónovej siete. Umelá neurónová sieť pozostáva zo vstupnej vrstvy neurónov, dvoch až troch skrytých vrstiev a jednej

výstupnej vrstvy. Takýto príklad architektúry môžeme vidieť na obrázku 2.6.



Obr. 2.6: Príklad umelej neurónovej siete

Do neurónov vo vstupnej vrstve prichádzajú vstupné dáta použité pre výpočet. Napríklad v prípade, že naše dáta obsahujú záznamy pozostávajúce s vektoru hodnôt, tak každý záznam do siete vstupuje samostatne, a každá hodnota zo záznamu vstupuje do samostatného neurónu. Počet neurónov vo vstupnej vrstve sa teda odvíja od dimenzii vstupných dát.

Neuróny sú medzi sebou prepojené a každý neurón skrytej vrstvy v sebe uchováva parameter nazývaný váhy. Môžeme si ho predstaviť ako vektor hodnôt, ktoré korešpondujú s každým spojením s neurónmi z predošlej vrstvy.

Hlavnou časťou matematickej operácie, za ktorú je neurón zodpovedný je vytvoriť skalárny súčin váh a vstupov do každého neurónu. Pre neurón i s váhami V_i a s N prepojeniami z predošlej vrstvy x_j je výsledok h_i vyjadrený nasledujúcim vzťahom:

$$h_i = \sum_{j=0}^N V_{i,j}x_j + b_i \quad (2.1)$$

Parameter b_i v rovnici 2.1 sa nazýva bias. Má podobný význam ako koeficient c v prípade lineárnej funkcie $y = kx + c$, a teda posúva graf funkcie pozdĺž osi y , čím vieme docieľiť, že funkcia lepšie opisuje vstupné dáta. Aby sme v neurónovej sieti zachytili aj nelineárne vzťahy, používa sa aktivačná funkcia.. Vhodne zvolená aktivačná nelineárna funkcia taktiež do-

pomáha udržiavať výstupné hodnoty v obmedzenom intervale. Obľúbenou voľbou nelineárnej funkcie je sigmoid definovaná vzťahom 2.2, ktorá obmedzí hodnoty na interval $(0, 1)$:

$$\sigma(u) = \frac{1}{1 + \exp(-u)} \quad (2.2)$$

Medzi iné často používané nelineárne funkcie patrí napríklad hyperbolický tangens alebo ReLU. Všetky funkcie plnia rovnaký účel a líšia sa len v intervale výstupu, čo môže byť smerodajné pre riešenie rôznych problémov. Výsledný vzťah s použitím aktivačnej funkcie sigmoid σ potom vyzerá nasledovne:


$$h_i = \sigma\left(\sum_{j=0}^N V_{i,j}x_j + b_i\right) \quad (2.3)$$

Výstupná vrstva je zodpovedná za produkovanie celkového výsledku, ktorého interpretácia závisí na riešenom probléme. Napríklad hodnoty z intervalu $(0, 1)$ môžeme interpretovať ako pravdepodobnosti príslušnosti k nejakej triede objektov v prípade problému klasifikácie.

V prípade obrazových vstupných dát pri využití umelých neurónových sietí môžeme použiť priamo obrazy ako vstup alebo môžeme prv vyextrahovať z obrazu príznaky a tie použiť ako vstup. V prvom prípade narazíme na problém, že neurónová sieť tak bude mať veľa parametrov (váh a biasov), v druhom prípade sa musíme vysporiadať s nie ľahkou úlohou extrakcie príznakov. Oba problémy rieši iný druh neurónových sietí - konvolučné neurónové siete.

2.6 Konvolučné neurónové siete

Konvolučné neurónové siete nesú názov podľa jednej z ich vrstiev - konvolučnej vrstvy. Ako názov naznačuje, fungovanie tejto vrstvy je založený na matematickej operácii konvolúcia. Konvolúcia je matematická operácia, ktorá vykonáva skalárny súčin medzi vstupnými dátami a jadrom inak nazývaným aj filter. V prípade 2D konvolúcie sa jedná zväčša o maticu veľkosti 3x3, 5x5 alebo 7x7. 2D konvolúcia je veľmi častá operácia v oblasti spracovania obrazu a dokážeme ňou doceliť veľa efektov ako napríklad zašumenie obrazu, vyhladenie obrazu či detegovanie hrán, a preto je veľmi užitočným nástrojom pri extrakcii dôležitých vlastností obrazu v neurónových sieťach.




Obr. 2.7: Príklad 2D konvolúcie

Na obrázku 2.7 vidíme príklad 2D konvolúcie. Výsledný obraz vzniká postupným prikladaním filtra na pôvodný obraz.

Po vykonaní konvolúcie sa v rámci tejto vrstvy ešte aplikuje aktivačná nelineárna funkcia, ktorej význam sme si popísali v predošlej časti.

Ďalšou dôležitou vrstvou v týchto sieťach je podvzorkovacia vrstva, ktorá spravidla nasleduje po konvolučnej vrstve. Jej úlohou je znížiť dimenziu vstupu pre ďalšiu vrstvu, čím dosiahneme zníženie počtu trénovateľných parametrov v sieti, a tak aj urýchlenie samotného trénovania. Najčastejšia forma podvzorkovania je maximalizácia susedných pixelov s dimenziou 2x2,

kedy podvzorkujeme obraz na polovičnú veľkosť a hodnoty pixelov zodpovedajú maximálnej hodnote 2×2 oblastí v pôvodnom obraze. Príklad takéhoto podvzorkovania je vizualizovaný na obrázku 2.8.



Obr. 2.8: Podvzorkovanie s maximalizáciou

Okrem maximalizácie pixelov sa využíva ešte aj spriemerovanie, kedy je výslednou hodnotou priemer pixelov v okolí 2×2 v pôvodnom obraze.

2.7 Trénovanie neurónovej siete

Na dosiahnutie želaného riešenia problému je potrebné sieť natrénovať. Trénovanie siete je proces, pri ktorom sa iteračne menia trénovateľné parametre siete tak, aby sme čo najlepšie aproximovali výsledok ku pravým hodnotám. Na vyjadrenie rozdielu medzi výsledkom, ktorý vyprodukovala sieť a pravou hodnotou sa využíva stratová funkcia. Trénovanie siete na nízkej úrovni prebieha v dvoch krokoch. V doprednom chode sa do siete pošlú vstupné dáta a sieť pre ne vyprodukuje výsledok, ktorý je následne hodnotený stratovou funkciou, ktorá určí chybu, ktorú sieť spravila. Chyba následne ovplyvní druhý krok tréningu - spätný chod. V tomto kroku sa podľa chyby aktualizujú trénovateľné parametre siete. Takýto proces sa opakuje dovtedy, kým nie je systém stabilný a chyba siete nie je ustálená na minime.

Mechanizmus na spätné šírenie chyby pri tréningu siete sa nazýva gradientný zostup. Metóda gradientného zostupu je iteračná optimalizačná metóda, ktorá využíva vlastnosti gradientu, ktorý v danom bode určuje smer

najväčšieho rastu funkcie. Túto vlastnosť vieme využiť tak, že pre minimalizáciu chyby stratovej funkcie parametre siete posunieme v opačnom smere gradientu. Miera akou gradient k zmene prispieva je daná parametrom rýchlosti učenia, ktorý je zároveň hyperparametrom siete a jeho voľba vie do veľkej miery ovplyvniť úspešnosť a rýchlosť trénovania.

Kapitola 3

Predchádzajúce riešenia


V tejto kapitole si rozoberieme predchádzajúce riešenia problému a taktiež podobné problémy, ktorých riešenia prispeli k vyhotoveniu vlastného modelu.

3.1 Detekcia močových kameňov

Automatickou detekciou obličkových alebo močových kameňov sa zaoberalo už veľa výskumníkov. Prístup ku problému volili spravidla rozdielny. Zatiaľ čo niektoré riešenia boli postavené na klasických metódach strojového učenia, kde príznaky z obrazu boli extrahované manuálne, iné využívali komplexné modely konvolučných neurónových sietí v predchádzajúcich zložitou sériou predspracovania dát. Keďže naša práca má za cieľ riešenie problému močových kameňov prostredníctvom konvolučných neurónových sietí, spomenieme si niekoľko existujúcich riešení, ktorými sme sa inšpirovali pri tvorbe vlastného modelu.

V riešení [LJT⁺18] pracovali s datasetom o veľkosti 465 CT skenov o rozmeroch 0.8mm x 0.8mm x 1mm. Každý sken najprv spracovali rovnakým spôsob, a síce, použili prahovú hodnotu 250HU na označenie oblastí, ktoré


potenciálne môžu byť kameňom. Následne sú posudzované všetky súvislé oblasti podľa ich rozmerov a na ďalšie spracovanie sa vybrali len tie, ktoré majú objem medzi 5 a 500 voxelov zodpovedajúci približne rozmerom gule o polomere 2 až 9 mm čo je obvyklý tvar kameňov. Výsledné súvislé oblasti tvoria základ vstupných dát pre neurónovú sieť. V práci skúmali rôzne formáty vstupných dát - 2D, 2.5D a 3D, zobrazené na obrázku 3.1.



Obr. 3.1: Skúmané formáty vstupu pre neurónovú sieť (zdroj: [LJT⁺18])

Najvhodnejším formátom sa po vyhodnotení javil 2.5D formát pozostávajúci z 3 výrezoch veľkosti 11x11 v troch rovinách CT skenu, ktorý následne tvoril vstup pre konvolučnú neurónovú sieť. Na trénovanie bolo použitých 349 skenov a na testovanie 88. Model dosiahol na testovacích dátach sto-percentnú citlivosť, avšak dosahoval pomerne veľkú priemernú mieru falošne pozitívnych nálezov na sken - $3:7 \pm 4:9$. Na zlepšenie výsledkov autori využili anatomickú informáciu o pravdepodobnosti výskytu močových kameňov. Z dát zostrojili pomocou gaussovského zmiešaného modelu (GMM) pravdepo-

dobnostnú mapu výskytu kameňa pre každý voxel skenu. Výsledná úspešnosť modelu je potom lineárnou kombináciou výsledkov z konvolučnej neurónovej siete a pravdepodobnostnej mapy pomocou. Koeficient α vyjadrujúci pomer medzi jednotlivými modelmi vo výslednom vzorci bol na základe skúmania viacerých hodnôt vybraný $\alpha = 0.6$.




Obr. 3.2: FROC krivka pre rôzne koeficienty α (zdroj: [LJT⁺18])

Výsledný model dával priemerne 2.82 falošne pozitívnych nálezov pre sken, čo je zlepšenie o 27.4% oproti modelu bez použitia pravdepodobnostnej mapy.

3.2 Detekcia pľúcnych nodulov

Autori článku [YM16] sa zamerali na automatickú detekciu nodulov z CT snímok pľúc. Na úvod sa na všetky skeny použije algoritmus, ktorý vysegmentuje z CT snímok len oblasť pľúc, čím zmenší skúmanú oblasť o nerelevantné údaje. Na segmentáciu je využitá informácia o priemernej hodnote HU pre tkanivo pľúc. Použitím prahu -480HU autori vytvorili binárnu masku pľúc, ktorú následne ešte vyhladili a odstránili diery pomocou morfologickej dila-

tácie. Použitím tejto masky dosiahli z CT snímok vierohodnú segmentáciu pľúc. Tento proces môžeme vidieť na obrázku 3.3.




Obr. 3.3: Segmentácia pľúc z CT použitím prahovej hodnoty HU škály (zdroj: [YM16])

Cieľom práce autorov bolo rozlišovať medzi voxelmi, ktoré patria zdravému tkaniv, a ktoré sú pľúcnyimi nodulmi. Rozhodli sa teda vytvoriť si z pôvodného datasetu vlastný dataset, ktorý by konkrétnejšie obsahoval príklady pre tieto dve kategórie. Vysegmentované pľúca navzorkovali na menšie oblasti, pričom vzorkovacia vzdialenosť bola určená ako 25-násobok dĺžky pixelu v danom smere pre každý rez CT skenu. Následne sú voxelom v navzorkovaných oblastiach určené kategórie na základe anotácií pôvodných CT skenov, ktoré obsahujú informáciu o pozícii detekovaných pľúcnych nodulov.

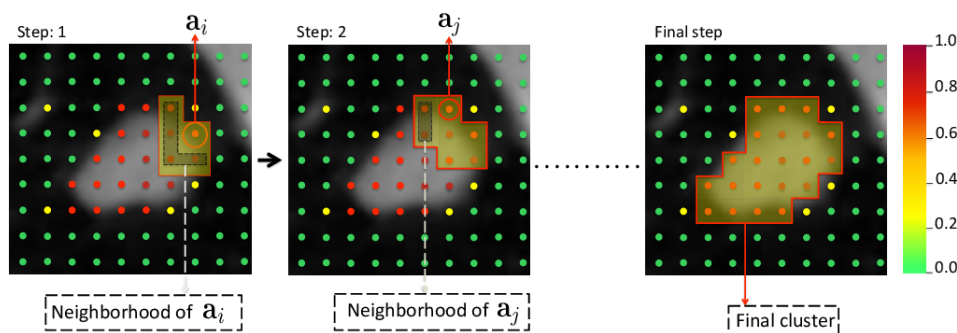
Pre lepšie zachovanie priestorovej informácie medzi jednotlivými rezmi skenu sa autori rozhodli pre každý anotovaný voxel z novo vytvoreného datasetu pridružiť aj korešpondujúce oblasti v príľahlých skenoch. Vznikla tým štruktúra pozostávajúca zo 7 2D obrázkov veľkosti 50x50, pričom stredný obrázok obsahuje práve anotovaný voxel. Vzorkovanie a vytvorenie štruktúry s obrázkami môžeme vidieť na obrázku 3.4

Takto vytvorená štruktúra obrázkov je vstupom pre neurónovú sieť. Autori v práci porovnávajú dva rôzne modely neurónovej siete - čisto konvolučnú



Obr. 3.4: A) vzorkovanie vysegmentovaných pľúc B) vytváranie štruktúry po sebe nasledujúcich rezov skenu C) výsledná štruktúra zachytávajúca priestorovú informáciu okolo skúmaného voxelu (zdroj: [YM16])

neurónovú sieť a konvolučnú neurónovú sieť s dvomi LSTM vrstvami, ktorú nazvali ReCTNet. Výsledkom oboch modelov je pravdepodobnosť že daný voxel je pľúcnym nodulom. Poslednou fázou detekcie je zlúčenie voxelov s pravdepodobnosťou nad určenú prahovú hodnotu $p = 0.5$ do nodulov. Proces zlučovania voxelov do nodulov je zobrazený na obrázku 3.5



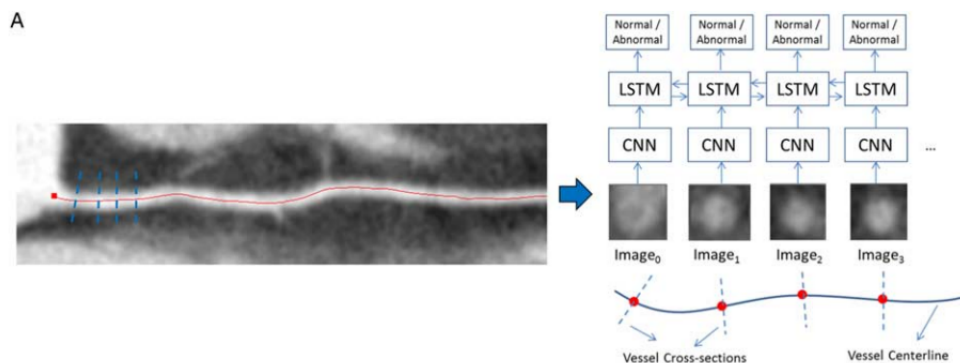
Obr. 3.5: Proces zlučovania voxelov do súvislých oblastí reprezentujúcich pľúcne noduly (zdroj: [YM16])

Výsledná úspešnosť oboch modelov je meraná prostredníctvom citlivosti a priemerného počtu falošne pozitívnych nálezov na sken. Model ReCTNet dosahoval citlivosť 90.5% pre priemerne 4.5 falošne pozitívnych nálezov na

sken a plne konvolučný model dosahoval citlivosť 81.8% pre priemerne 6.8 falošne pozitívnych nálezov na sken.

3.3 Detekcia plakov v srdcovej tepne

Riešenie [FEDC⁺20] sme si pri výskume vybrali kvôli podobnosti detegovaného objektu, keďže plak v tepne má podobné zloženie ako močové kamene, a tak má na CT skene obdobný vzhľad. Algoritmus navrhnutý v tejto práci najprv deteguje osrdcovník a následne ústie do pravej a ľavej vencovitej tepny. Tie slúžia na detekciu tzv. *centerline tree* vedúcou stredom oboch tepien. Následne sú pozdĺž tepien v smere centerline vytvorené 2D okolia, ktoré sú následne vstupom pre konvolučnú neurónovú sieť. Tento postup vizuálne popisuje obrázok 3.6



Obr. 3.6: Vytváranie rezov pozdĺž tepny ako vstup pre model s LSTM architektúrou (zdroj: [FEDC⁺20])

Model neurónovej siete použitej v tejto práci je založený na architektúre LSTM, ktorú sme si bližšie popísali v predošlej časti Teoretické východiská. Celková citlivosť navrhnutého modelu bola 92.1%.

Kapitola 4

Návrh modelu

Kapitola 5

Implementácia

Kapitola 6

Výsledky

Kapitola 7

Záver

Literatúra

- [FEDC⁺20] Andreas M Fischer, Marwen Eid, Carlo N De Cecco, Mehmet A Gulsun, Marly Van Assen, John W Nance, Pooyan Sahbaee, Domenico De Santis, Maximilian J Bauer, Brian E Jacobs, et al. Accuracy of an artificial intelligence deep learning algorithm implementing a recurrent neural network with long short-term memory for the automated detection of calcified plaques from coronary computed tomography angiography. *Journal of thoracic imaging*, 35:S49–S57, 2020.
- [LJT⁺18] Martin Långkvist, Johan Jendeberg, Per Thunberg, Amy Loutfi, and Mats Lidén. Computer aided detection of ureteral stones in thin slice computed tomography volumes using convolutional neural networks. *Comput. Biol. Medicine*, 97:153–160, 2018.
- [ON15] Keiron O’Shea and Ryan Nash. An introduction to convolutional neural networks. *ArXiv e-prints*, 11 2015.
- [PLL⁺19] Anushri Parakh, Hyunkwang Lee, Jeong Hyun Lee, Brian H. Eisner, Dushyant V. Sahani, and Synho Do. Urinary stone detection on ct images using deep convolutional neural networks: Evaluation of model performance and generalization. *Radiology: Artificial Intelligence*, 1(4):e180066, 2019. PMID: 33937795.

[Sue17] Paul Suetens. *Fundamentals of medical imaging*. Cambridge university press, 2017.

[THNA18] Nilar Thein, Kazuhiko Hamamoto, Hanung Adi Nugroho, and Teguh Bharata Adj. A comparison of three preprocessing techniques for kidney stone segmentation in ct scan images. In *2018 11th Biomedical Engineering International Conference (BMEiCON)*, pages 1–5, 2018.

[YM16] Petros-Pavlos Ypsilantis and Giovanni Montana. Recurrent convolutional networks for pulmonary nodule detection in ct imaging. *CoRR*, abs/1609.09143, 2016.

Zoznam obrázkov

| | | |
|-----|---|----|
| 2.1 | Vizualizácia troch osí CT skenu | 4 |
| 2.2 | Schematická reprezentácia fungovania CT skeneru (zdroj: [Sue17]) | 5 |
| 2.3 | Zmena obrazu pri úprave šírky a stredu okna mapovania . . . | 6 |
| 2.4 | Tagy DICOM súboru zobrazené v softvéri Micro Dicom Viewer | 7 |
| 2.5 | Ukážka možnej štruktúry DICOM súborov v softvéri Micro Dicom Viewer | 8 |
| 2.6 | Príklad umelej neurónovej siete | 9 |
| 2.7 | Príklad 2D konvolúcie | 11 |
| 2.8 | Podvzorkovanie s maximalizáciou | 12 |
| 3.1 | Skúmané formáty vstupu pre neurónovú sieť (zdroj: [LJT ⁺ 18]) | 15 |
| 3.2 | FROC krivka pre rôzne koeficienty α (zdroj: [LJT ⁺ 18]) . . . | 16 |
| 3.3 | Segmentácia pľúc z CT použitím prahovej hodnoty HU škály (zdroj: [YM16]) | 17 |
| 3.4 | A) vzorkovanie vysegmentovaných pľúc B) vytváranie štruk- túry po sebe nasledujúcich rezov skenu C) výsledná štruktúra zachytávajúcu priestorovú informáciu okolo skúmaného voxelu (zdroj: [YM16]) | 18 |
| 3.5 | Proces zlučovania voxelov do súvislých oblastí reprezentujú- cich pľúcne noduly (zdroj: [YM16]) | 18 |

| | | |
|-----|---|----|
| 3.6 | Vytváranie rezov pozdĺž tepny ako vstup pre model s LSTM architektúrou (zdroj: [FEDC ⁺ 20]) | 19 |
|-----|---|----|